3GPP 요구사항의 한국어 설명에서 규범적 의미 보존을 위한 증거 제약 생성 평가

김태훈[1]
[1]제주대학교 통신공학과 학부생
xogns.k98@gmail.com

Evaluating Evidence-Constrained Generation for Preserving Normative Meaning in Korean Explanations of 3GPP Requirements

Taehoon Kim[1]
[1]Department of Telecommunications Engineering, Jeju National University

요 약

3GPP 영문 규격의 한국어 설명에서 규범 강도 · 행위자 · 조건 · 행동 · 예외의 보존을 평가했다. TS 23.501과 TS 24.501 V18.12.0의 동결 응답을 사후 적격성 감사와 동일 AI의 지연 재검토로 재평가했다. 주 분석 49건에서 완전 보존 성공은 원문 단독(C1) 38건, 정답 구조(C2) 44건, 자동 추출 구조(C3) 41건, 정답 유형 · 부정 힌트(C1M) 43건이었다. 미확정을 유지한 보존율 범위는 각각 77.55~79.59%, 89.80~93.88%, 83.67~87.76%, 87.76~91.84%다. 확정 판정을 고정하면 세 조건의 C1 대비 차이는 양수이나, 이 범위는 신뢰구간이 아니며 통계적 우월성이나 일반화를 뜻하지 않는다. 사후 표본 선정과 단일 AI 평가의 한계가 있어 독립 전문가 및 새 조항 검증이 필요하다.

키워드: 3GPP, 대규모 언어 모델, 규범 언어, 의미 보존, 증거 제약

1. 서론

3GPP 기술규격은 이동통신 시스템의 구조와 프로토콜 동작을 정의한다. ETSI 작성 규칙에서 shall/shall not은 의무 · 금지, should/should not은 권고 · 비권고, may는 허용, can은 가능 또는 능력을 뜻한다〔1〕. may와 can은 한국어에서 모두 '~할 수 있다'로 표현되기 쉬우나 규범적 의미는 다르다. 행위자, 적용 조건 또는 예외까지 바뀌면 구현과 시험 판단도 달라질 수 있다.

기존 연구는 3GPP 데이터셋과 질의응답〔2〕, 통신 규격 RAG〔3〕, 한국어 통신 에이전트 평가〔4〕, 교차 참조 · 버전 변화 검색〔5〕, 규범 해석 · 보안 추론〔6〕을 다뤘다. 법률 번역에서도 계층적 제약으로 규범 강도를 보존하는 접근이 제안됐다〔7〕. 본 연구는 고정된 3GPP 문장의 한국어 설명을 규범 요소별로 평가하고, 원문 단독 · 정답 구조 · 자동 추출 구조 조건을 비교한다.

연구 질문은 원문 단독(C1)에 정답 구조(C2) 또는 자동 추출 구조(C3)를 추가할 때 한국어 설명의 완전 의미 보존율이 어떻게 달라지는가이다. 정답 규범 유형 · 부정만 추가한 C1M도 비교한다. 본고는 동결된 응답의 표본 적격성 재점검과 지연 재평가를 보고하며, 실제 검색 정확도나 3GPP 전체 일반화는 다루지 않는다.

2. 연구 방법

원문은 ETSI 공식 배포본인 TS 23.501 및 TS 24.501 V18.12.0 Release 18로 고정했다〔8〕, 〔9〕. 최초 표본은 7,727개 후보에서 선정한 72개 문장(규범 유형 6종별 12개, 44개 조항)이다. 생성 후 적격성을 다시 감사해 일반 적격 50건, 조건부 예외 1건, 부적격 10건, 보류 11건으로 구분했다. 주 분석은 일반 적격 중 C2 정답 입력 오염 1건(MAY-001)을 제외한 49건 · 33개 조항이다. 제외 기준은 사후에 마련해 이번 재평가 전에 동결했다. 원문 · 질문 · 기존 응답은 수정하거나 재생성하지 않았다.

C0는 원문 없는 질문 조건이다. C1은 원문과 의미 보존 지시를, C2는 원문과 정답 actor · modal · polarity · condition · action · exception을 받는 oracle structured 조건이다. C3는 질문 · 정답 없이 원문에서 여섯 필드를 자동 추출한 뒤 설명하고 불명확하면 보류한다. C1M은 C1에 정답 modal · polarity만 추가한다. 모델은 gpt-5.4-mini-2026-03-17, temperature 0, reasoning effort none, 출력 상한 600 tokens이며 C3 추출은 1,200

tokens다. C1/C2는 9월 3일, C3/C1M은 9월 6일 생성했다. C2와 C1M은 정답 힌트를 쓰므로 자동 추출 성능과 구분한다.

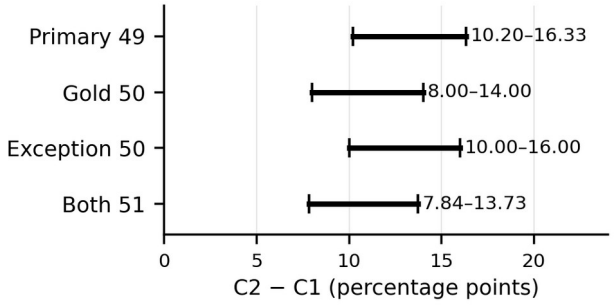
행위자·규범 강도와 부정·조건·행동·예외를 모두 보존하고 미지원 규범을 추가하지 않으면 P(성공), 명확한 위반이면 F(실패), 의미 판정을 확정할 수 없으면 U(미확정)로 평가했다. 미생성 NG는 의미 오류와 구분하되 분모에 포함해 성공 0건으로 계산한다. 51건×5조건의 255개 슬롯을 동일 Codex가 9월 8일 평가하고 24시간 이상 후 재검토해 불일치 5건을 조정했다. 기존 결과를 아는 동일 AI의 검토이므로 독립 맹검이나 전문가 검증은 아니다. 확정 판정을 고정하고 U를 모두 실패 또는 성공으로 둘 때의 P/N~(P+U)/N만 보고한다. 이는 신뢰구간이 아니며 U가 남은 추론 통계는 보류했다.

3. 실험 결과

<표 1> 주 분석 49건의 완전 의미 보존 결과

조건	P	F	U / NG	보존율 범위(%)
C0	0	49	0 / 0	0.00~0.00
C1	38	10	1 / 0	77.55~79.59
C2	44	3	2 / 0	89.80~93.88
C3	41	5	2 / 1	83.67~87.76
C1M	43	4	2 / 0	87.76~91.84

표 1의 범위는 미확정 판정에 따른 논리적 상·하한이다. C1은 P 38건·U 1건, C2는 P 44건·U 2건이며 C2−C1은 +10.20~+16.33%p다. C3−C1은 +4.08~+10.20%p, C1M−C1은 +8.16~+14.29%p다. 주 분석의 U 7건과 C3 미생성 1건은 모두 분모에 남겼다. C0의 0/49는 원문 없는 조건에서 이 완전 보존 기준을 충족하지 못한 결과다.



(그림 1) 표본별 C2−C1 논리적 범위(신뢰구간 아님)

민감도 분석은 주 분석에 입력 오염 사례를 복원한 Gold 50, 조건부 예외(SDN-011)를 복원한 Exception 50, 둘 다 복원한 Both 51이다(그림 1). 평가 정답의 보정은 원래 C2 입력의 오염을 제거하지 않는다. 네 표본 모두 C2·C3·C1M의 C1 대비 차이 하한은 양수지만, 이는 확정 판정을 고정한 기술적 비교이며 모집단의 우월성을 입증하지 않는다. 표본이 서로 중첩되므로 독립 반복 실험도 아니다.

C2−C1M은 주 분석에서 −2.04~+6.12%p이고 세 민감도 표본에서도 0을 포함한다. 따라서 전체 정답 구조와 유형·부정 힌트의 순위 또는 동등성을 확정할 수 없다. 출처 참조만으로 판단이 해소되지 않은 사례는 U로 유지했다. JSON의 규범 유형이나 인용 ID가 맞아도 설명의 주체·행동·조건 연결을 대신 검증할 수 없으므로, 메타데이터 일치를 의미 보존 성공으로 간주하지 않았다.

4. 결론 및 한계

동결 응답의 사후 재평가에서 정답 구조·자동 추출 구조·규범 유형 힌트 조건은 원문 단독보다 높은 완전 보존 범위를 보였다. 다만 이 결과는 확정 판정과 선정 표본에 조건부인 기술적 관찰이다. 규범 유형 이름뿐 아니라 그것이 적용되는 주체·행동과 조건·예외의 범위를 함께 평가해야 하며, 단일 AI의 재검토 일치는 정답 타당도를 보장하지 않는다.

본 연구는 단일 모델·두 규격의 고정 버전과 Codex 기반 정답·평가에 한정된다. 사후 표본 제외, 조항 내 의존성, 미확정 판정이 남아 통계적 유의성이나 일반화를 주장하지 않는다. C2와 C1M은 지시문도 달라 순수한 구조 효과를 분리하지 못하며 생성일 차이도 남는다. 후속 개발 사례는 본 분석에 합치지 않았다. 독립 전문가 판정과 개발에 사용하지 않은 새 조항 검증이 필요하다.

참고문헌

〔1〕 ETSI, "ETSI Drafting Rules," Clause 3.2, Verbal forms for the expression of provisions, 2026.

〔2〕 R. Nikbakht, M. Benzaghta, and G. Geraci, "TSpec-LLM: An Open-source Dataset for LLM Understanding of 3GPP Specifications," arXiv:2406.01768, 2024.

〔3〕 G. M. Yilma, J. A. Ayala-Romero, A. Garcia-Saavedra, and X. Costa-Perez, "TelecomRAG: Taming Telecom Standards with Retrieval Augmented Generation and LLMs," arXiv:2406.07053, 2024.

〔4〕 S. Lee et al., "TelAgentBench: A Multi-faceted Benchmark for Evaluating LLM-based Agents in Telecommunications," Proc. EMNLP Industry Track, pp. 1173-1211, 2025.

〔5〕 A. G. Manvattira, Y. Xu, Z. Dang, and S. Lu, "DeepSpecs: Expert-Level Question Answering in 5G," Findings of ACL, pp. 26935-26953, 2026.

〔6〕 K. Xie, X. Zhao, Y. Hu, S. Yuan, and T. Xie, "CellularSpecSec-Bench: A Staged Benchmark for Evidence-Grounded Interpretation and Security Reasoning over 3GPP Specifications," arXiv:2601.12716, 2026.

〔7〕 L. Meng et al., "Beyond multi-agent translation: engineering fidelity in legislative text translation via hierarchical control," Artificial Intelligence and Law, 2026, doi:10.1007/s10506-026-09529-2.

〔8〕 ETSI, "5G; System architecture for the 5G System (5GS)," ETSI TS 123 501 V18.12.0, 3GPP TS 23.501 Release 18, 2026.

〔9〕 ETSI, "5G; Non-Access-Stratum (NAS) protocol for 5G System (5GS); Stage 3," ETSI TS 124 501 V18.12.0, 3GPP TS 24.501 Release 18, 2025.