3GPP 요구사항의 한국어 설명에서 규범적 의미 보존을 위한 증거 제약 생성 평가

김태훈[1]
[1]제주대학교 통신공학과 학부생
xogns.k98@gmail.com

Evaluating Evidence-Constrained Generation for Preserving Normative Meaning in Korean Explanations of 3GPP Requirements

Taehoon Kim[1]
[1]Department of Telecommunications Engineering, Jeju National University

요 약

3GPP 영문 규격의 한국어 설명에서 규범 강도·행위자·조건·행동·예외의 보존을 평가했다. 동결 응답의 사후 적격성 감사와 동일 AI 의 지연 재검토 후, 주 분석 49 건의 완전 보존 범위는 원문 단독 77.55~79.59%, 정답 구조 89.80~93.88%, 자동 추출 구조 83.67~87.76%, 정답 유형·부정 힌트 87.76~91.84%였다. 이는 미확정에 따른 논리적 범위이며 신뢰구간이 아니다. 별도 개발 원문 3 개에서 추가 생성된 8 개 설명의 지정 요구사항 재검토로 규범 강도 변경과 조건·예외 누락을 확인했다. 메타데이터가 맞아도 설명의 명제 연결이 달라질 수 있어 두 평가를 구분해야 한다. 사후 표본 처리와 단일 AI 평가의 한계가 있으며 통계적 우월성이나 일반화를 주장하지 않는다.

키워드: 3GPP, 대규모 언어 모델, 규범 언어, 의미 보존, 증거 제약

1. 서론

3GPP 규격의 shall/shall not 은 의무·금지, should/should not 은 권고·비권고, may 는 허용, can 은 가능·능력을 뜻한다[1]. may 와 can 은 한국어에서 모두 “~할 수 있다”로 표현되기 쉽다. 강도뿐 아니라 행위자·조건·예외의 변경도 구현과 시험 판단에 영향을 줄 수 있다.

기존 연구는 3GPP 데이터셋·질의응답[2], 통신 규격 RAG[3], 한국어 통신 에이전트[4], 교차 참조·버전 검색[5], 규범·보안 추론[6]을 다뤘다. 법률 번역에는 계층적 제약으로 규범 강도를 보존하는 접근이 있다[7]. 본 연구는 고정 문장의 한국어 설명에서 규범 요소의 보존을 비교한다.

원문 단독(C1), 정답 구조(C2), 자동 추출 구조(C3), 정답 유형·부정 힌트(C1M)의 의미 보존을 비교한다. 고정 응답의 사후 재평가이며 검색 정확도와 3GPP 전체 일반화는 다루지 않는다.

2. 연구 방법

ETSI 배포 TS 23.501·24.501 V18.12.0 Release 18[8], [9]의 7,727 개 후보에서 pilot 결과를 참고해 규격·규범 유형·난도별로 층화하고 문서 순서로 72 문장·44 조항을 비무작위 선정했다(유형별 12 개). 후보 부족 예외와 입력은 main 생성 전인 9 월 3 일 동결했다. 이후 결과를 아는 동일 AI 가 적격성을 재감사해 일반 적격 50·조건부 예외 1·부적격 10·보류 11 건을 기록했다. 부적격은 NOTE·목록 규칙 위반, 보류는 문맥·대응·메타데이터·의미 중복 문제다. 9 월 8 일 재평가 전에 별도 사후 처리 기준을 동결하고, C2 정답 입력이 오염된 MAY-001 을 모든 조건에서 제외한 49 문장·33 조항을 주 분석으로 삼았다. 최초 실험의 사전 등록은 아니며 기존 입력·응답은 보존했다.

C0 는 질문만, C1 은 원문과 의미 보존 지시를 받는다. C2 는 원문에 정답 행위자·규범 유형·부정·조건·행동·예외를, C1M 은 정답 modal·polarity 만 더한다. C3 는 원문만으로 구조를 추출하고 질문·원문·추출 필드로 설명하며 불명확한 추출은 보류한다. 생성 모델은 gpt-5.4-mini-2026-03-17, temperature 0, reasoning effort none, 출력 상한 600 tokens(C3 추출 1,200)다. C1/C2 는 9 월 3 일, C3/C1M 은 9 월 6 일 생성했다. C2/C1M 의 정답 힌트와 지시문·생성일 차이 때문에 순수한 구조 효과를 분리하지 못한다.

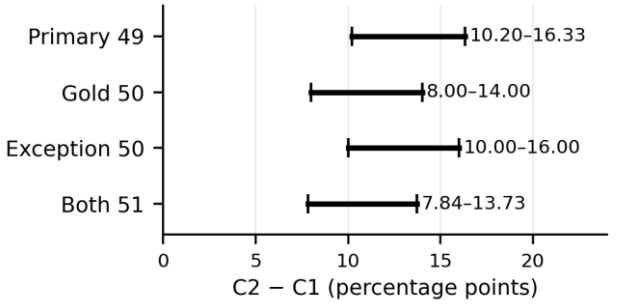
원문 근거와 필수 명제를 전체 explanation_ko 에 대조해 모두 보존하고 미지원 규범 추가가 없으면 P, 명백한 위반은 F, 판정 미확정은 U 로 기록했다. 메타데이터로 설명 누락을 보충하지 않는다. 미생성 NG 는 의미 오류와 구분하되 고정 분모에서 성공 0 이다. 합집합 51 건×5 조건을 동일 Codex 가 9 월 8 일 평가하고 25 시간 10 분 뒤 다른 가림 순서로 재검토했다. 당시 1 차 판정 파일과 조건 키는 열지 않았으나 대화에 이전 내용이 남아 독립 맹검은 아니다. 250/255 상태가 일치했고 불일치 5 건을 P 2·F 2·U 1 로 조정했다. 일치는 정답률이 아니다. P/N~(P+U)/N 은 확정 판정에 조건부인 U 의 논리적 범위이며 신뢰구간이 아니다. U 가 남은 추론 통계는 보류했다.

3. 실험 결과

<표 1> 주 분석 49 건의 완전 의미 보존 결과

조건	P	F	U / NG	보존율 범위(%)
C0	0	49	0 / 0	0.00~0.00
C1	38	10	1 / 0	77.55~79.59
C2	44	3	2 / 0	89.80~93.88
C3	41	5	2 / 1	83.67~87.76
C1M	43	4	2 / 0	87.76~91.84

C2−C1 은 +10.20~+16.33%p, C3−C1 은 +4.08~+10.20%p, C1M−C1 은 +8.16~+14.29%p 다. 주 분석의 U 7 응답과 C3 미생성 1 건은 분모에 남겼다. U 는 저장 규칙의 참조 범위와 위성 접속의 상위 문맥이 원래 입력·평가 범위에서 확정되지 않은 데서 남았다. C0 의 0/49 는 원문 없는 조건에서 이 완전 보존 기준을 충족하지 못한 결과다.



(그림 1) 표본별 C2−C1 논리적 범위(신뢰구간 아님)

MAY-001 을 더한 Gold 50, 목록 예외 SDN-011 을 더한 Exception 50, 둘 다 더한 Both 51 에서도 C2·C3·C1M 의 C1 대비 차이 하한은 양수였다(그림 1). 채점 정답 보정은 기존 C2 입력 오염을 제거하지 않는다. 중첩 집합은 독립 반복이 아니며 이 차이는 모집단 우월성이 아니다. C2−C1M 은 주 분석 −2.04~+6.12%p 이고 모든 민감도에서 0 을 포함해 순위나 동등성을 확정하지 못한다.

판정 경계를 보이기 위해 불일치 5 건 중 성공·실패·미확정 대표 사례를 제시한다. Active Time 할당 시 all-PLMN 영역의 비권고를 완결한 뒤 목적을 재언급한 설명은 추가 제한을 명시하지 않아 P 로 조정했다. 반면 TS 24.501 §4.4.4.2 의 “unless they have been successfully integrity checked”에서 they 는 NAS 메시지인데, 응답은 “UE 의 수신 5GMM 엔티티가 NAS 에 의해 성공적으로 무결성 검사를 받은 경우”로 바꿔 F 다. 민감도에만 포함된 SMF 사례는 “능력이 있다” 뒤 “이는 허용 또는 선택 가능”의 지시 대상이 불명확해 U 를 유지했다. 이는 새 채점이 아니라 기존 조정 근거다.

별도 개발 원문 SMF(§4.2.3)·AMF(§5.4.11.4)[8]·NSSAI(§4.6.2.2 및 Annex C)[9]에 문맥을 주고 각 3 회 설명을 계획했다(9 월 14 일, 동일 모델, temperature 0, 2~4 문장, 900 토큰). 통신 미상 1 회는 재시도하지 않았다. 동결한 SMF 2·NSSAI 4·AMF 3 개 요구사항 각각의 모든 필수 요소를 설명에서 확인했다. 능력 보유의 선택성, SUPI 결합, 긴급·eCall 의 저장·삭제 예외, 위치 판단의 권고·위성 범위·망 설정이 대상이며 문맥 전체의 완역 지표는 아니다. 완료 8 개는 당일 동일 AI 재검토 후 완수 3·미완수 5 였다(SMF 2/2, NSSAI 1/3, AMF 0/3).

AMF 3 개에는 강도 변경·망 설정 조건 미보존, NSSAI 2 개에는 eCall 예외 누락이 남았다. “저장해야 한다는 권고”는 전체 표현이 권고를 명시해 강도 오류로 세지 않았다. 별도 AI 문맥의 기존 3 원문×5 조건 검토는 P 1·F 6·U 8 로 15/15 일치했다. 반면 같은 개발 원문 3 개에 3 지시를 적용해 2 회씩 생성한 별도 실험에서 두 AI 의 전체 완수 여부 판정은 18 건 중 15 건, 세부 요구사항 판정은 54 건 중 46 건에서 일치했다. 두 결과 모두 선정 사례의 보조 근거이며 동일 모델 계열 AI 의 오류 독립성이나 사람 평가 신뢰도를 뜻하지 않는다. 주 결과와 합산하지 않았다.

4. 결론 및 한계

정답 힌트·자동 추출 조건의 C1 대비 차이는 이 고정 표본에서 양수지만 C2 와 C1M 의 우열은 미정이다. 규범 유형만으로는 검사 대상·조건·예외의 오류를 잡지 못하므로 설명의 명제 연결과 판정 근거를 함께 제시해야 한다.

정답 작성과 주 평가는 동일 Codex 에 의존하며 독립 사람 검토는 미실시다. 평가 모델의 정확한 snapshot 식별 기록도 없어 생성 모델과 구분한다. 단일 생성 모델·고정 규격·사후 표본 처리·조항 의존성·미확정의 한계가 있다. pilot 과 초기 main 의 동일 원문은 0 건이나, 조항은 초기 main 과 9 개, 주 분석과 7 개가 중복됐다. 추가 진단은 알려진 원문의 반복이며, 기존 판정을 아는 AI 가 같은 날 재검토했으므로 독립·지연 검증이 아니다. 통신 미상은 의미 오류와 구분했다. 근거 추적과 계산 일치가 의미적 정답을 보증하지 않으며 독립 검토와 새 조항 검증이

필요하다.

참고문헌

[1] ETSI, "ETSI Drafting Rules," Clause 3.2, Verbal forms for the expression of provisions, 2026.

[2] R. Nikbakht, M. Benzaghta, and G. Geraci, "TSpec-LLM: An Open-source Dataset for LLM Understanding of 3GPP Specifications," arXiv:2406.01768, 2024.

[3] G. M. Yilma, J. A. Ayala-Romero, A. Garcia-Saavedra, and X. Costa-Perez, "TelecomRAG: Taming Telecom Standards with Retrieval Augmented Generation and LLMs," arXiv:2406.07053, 2024.

[4] S. Lee et al., "TelAgentBench: A Multi-faceted Benchmark for Evaluating LLM-based Agents in Telecommunications," Proc. EMNLP Industry Track, 2025, pp. 1173-1211.

[5] A. G. Manvattira, Y. Xu, Z. Dang, and S. Lu, "DeepSpecs: Expert-Level Question Answering in 5G," Findings of ACL, 2026, pp. 26935-26953.

[6] K. Xie, X. Zhao, Y. Hu, S. Yuan, and T. Xie, "CellularSpecSec-Bench: A Staged Benchmark for Evidence-Grounded Interpretation and Security Reasoning over 3GPP Specifications," arXiv:2601.12716, 2026.

[7] L. Meng et al., "Beyond multi-agent translation: engineering fidelity in legislative text translation via hierarchical control," Artificial Intelligence and Law, 2026, doi:10.1007/s10506-026-09529-2.

[8] ETSI, "5G; System architecture for the 5G System (5GS)," ETSI TS 123 501 V18.12.0, 3GPP TS 23.501 Release 18, 2026.

[9] ETSI, "5G; Non-Access-Stratum (NAS) protocol for 5G System (5GS); Stage 3," ETSI TS 124 501 V18.12.0, 3GPP TS 24.501 Release 18, 2025.